1. O Ambiente e a Descrição do Estado (S)

SNAKE GAME MDP



Observabilidade Total

O agente enxerga o tabuleiro inteiro a cada instante. Não há incerteza sobre o estado atual, caracterizando um **MDP completo** (e não um POMDP).

01 **Cobra: Cabeça & Corpo Ordenado**

Lista de coordenadas $[(x_0,y_0), (x_1,y_1), ..., \text{cauda}]$. A direção atual é deduzida da cabeça em relação ao 2º segmento.

02 **Posição da Comida / Maçã**

Coordenada (x, y) da célula livre sorteada. Permite calcular distâncias e orientar a tomada de decisão.

03 **Contador de Passos Sem Comer**

Informa há quanto tempo o agente está andando sem alimento, evitando loops e mantendo a dinâmica markoviana.

Propriedade Markoviana Atendida

$P(s' \mid s, a)$ depende unicamente da situação atual do estado s e da ação a, dispensando o histórico passado de jogadas.

2. O Agente, Ações (A) e Transição P(s'|s,a)

SNAKE GAME MDP

Objetivo do Agente

Aprender uma política de controle em tempo real para encontrar comida, evitar colisões e maximizar a pontuação acumulada.

ESPAÇO DE AÇÕES A

- **Cima**
- **Baixo**
- **Esquerda**
- **Direita**

* Ações de 180° em relação à direção atual são inválidas (evita colisão no próprio pescoço).

Movimento Determinístico

Com base na ação selecionada, a cabeça avança 1 casa. Se não houver comida, a cauda é removida, mantendo o tamanho fixo.

Sorteio Estocástico da Comida

Ao comer, a cobra cresce 1 segmento e a próxima maçã aparece aleatoriamente em uma das células vazias com prob. uniformemente distribuída.

Condição de Término (Episódio)

A partida se encerra imediatamente ao haver colisão com as paredes limites ou com qualquer parte do próprio corpo.

3. Função de Recompensa (R) e Política Ótima

SNAKE GAME MDP



01

Comer (+10)

Recompensa positiva imediata ao alcançar a comida. Incentiva o cumprimento do objetivo principal.

Reforço Positivo



02

Colisão (−100)

Penalidade forte ao colidir com parede ou corpo. Torna o suicídio/morte pior que qualquer movimento de risco.

Penalidade Severa



03

Passo (−0.1)

Pequena custo por movimento sem progresso. Impede loops infinitos e força o agente a buscar caminhos curtos.

Eficiência Temporal

Síntese do Objetivo: Aprender uma **política ótima π*** que maximize o retorno acumulado descontado ao longo de múltiplos episódios.